

## 第六章点估计核心和预备知识

1. 概率函数  $f(x)$ :  $\begin{cases} \text{连续型分布的密度函数 } f(x) = p_f(x) \\ \text{离散型分布时 } f(x) = p(g=x) \end{cases}$

## 2. 母体矩和样本矩定义与关系

定义: 设  $g_1, \dots, g_n$  是来自母体  $g$  容量为  $n$  的子样, 则

①  $E(g)$  与  $\bar{g}$  分别为母体和子样的一阶原点矩.

②  $E(g^k)$  为母体的  $k$  阶原点矩,  $\bar{g}^k = \frac{1}{n} \sum_{i=1}^n g_i^k$  为子样的  $k$  阶原点矩.

关系①由大数定律知  $\bar{g} \xrightarrow{P} E(g)$ , 即子样均值依概率收敛于  $E(g)$ .

②由 R.H. 斯鲁茨基定理知  $R(\bar{g}^k) \xrightarrow{P} R(E(g^k))$  其中  $R$  为有理函数. 特别的  $\bar{g}^k \xrightarrow{P} E(g^k)$ , 即  $k$  阶子样原点矩依概率收敛于  $E(g^k)$ .

3. 矩法 (替换原则): 令  $\bar{g}^k = E(g^k)$  求未知参数.

替换原则 令  $\frac{1}{n} \sum_{i=1}^n x_i^k = E(x^k)$ , 母体分布中有几个未知参数, 则令  $k \leq$  未知参数个数.

例1. 设母体  $X \sim U(a, b)$ ,  $a, b$  未知 求  $a, b$  的矩法估计量.

解. 令  $x_1, \dots, x_n$  为一个样本.

$$\because E(X) = \frac{a+b}{2} \quad E(X^2) = \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4} \quad \text{所以令}$$

$$\frac{a+b}{2} = A_1, \quad \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4} = A_2$$

$$\Rightarrow a+b = 2A_1, \quad b-a = \sqrt{12(A_2 - A_1^2)}$$

具体解上面加一个箭头

$$\Rightarrow \hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{x} - \sqrt{\frac{3}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{x} + \sqrt{\frac{3}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\begin{aligned} \text{(注: } A_2 - A_1^2 &= \bar{x}^2 - \bar{x}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{n} \left( \sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) \\ &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{aligned}$$

例2. 设母体  $X$  的 pdf 为  $p_X(x) = \begin{cases} (2+1)x^2, & 0 < x < 1 \\ 0, & \text{其它} \end{cases}$ ,  $\theta > 0$  未知.

求  $\theta$  的矩法估计量

$$\begin{aligned} \text{解: } E(X) &= \int_0^1 x p_X(x) dx = \frac{2+1}{2+2} \quad \text{令 } \frac{2+1}{2+2} = \bar{x} \Rightarrow \\ \bar{x} &= \frac{2\theta-1}{1-\theta} \end{aligned}$$



例3. 设总体  $\xi \sim N(\mu, \sigma^2)$ ,  $\mu$  与  $\sigma^2$  未知. 求它们的矩估计量.

解:  $E(\xi) = \mu$ ,  $E(\xi^2) = E^2(\xi) + D(\xi) = \mu^2 + \sigma^2$

$\therefore$  矩估计有 
$$\begin{cases} E(\xi) = \mu = \bar{\xi} \\ E(\xi^2) = \mu^2 + \sigma^2 = \overline{\xi^2} \end{cases}$$

$$\Rightarrow \hat{\mu} = \bar{\xi}, \quad \hat{\sigma}^2 = \overline{\xi^2} - \hat{\mu}^2 = \overline{\xi^2} - \bar{\xi}^2 = \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi})^2 = S_n^2$$

$$\therefore \hat{\mu} = \bar{\xi}, \quad \hat{\sigma}^2 = S_n^2$$

4. 极大似然估计 (Maximum Likelihood estimate, MLE)  
最早是 Gauss 提出. Fisher 研究了统计推断应用.  
关键是概率函数之积, 构造似然函数.

离散型  $L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n p(\xi_i = x_i; \theta)$

连续型  $L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n p(\xi_i; \theta)$

挑选  $\hat{\theta}$ , 使  $L(x_1, \dots, x_n; \hat{\theta}) = \max L(x_1, \dots, x_n; \theta)$  这个  $\hat{\theta}$  与样本

有关,  $\hat{\theta}(x_1, \dots, x_n)$  为极大似然估计值,

$\hat{\theta}(\xi_1, \dots, \xi_n)$  为极大似然估计量.

常规做法把  $L(x_1, \dots, x_n, \theta)$  中的  $\theta$  按下面步骤给出.

① 取对数 ② 求导.

( $f(x)$  最大  $\Leftrightarrow \ln f(x)$  最大).

例: ① 设总体  $X \sim N(\mu, \sigma^2)$ ,  $x_1, \dots, x_n$  为样本值, 求  $\mu$  与  $\sigma^2$  的极大似然估计.

② 若  $\mu = \mu_0$  为已知, 求  $\sigma^2$  的极大似然估计.

解 ①  $\mu$  与  $\sigma^2$  都是未知参数.

$$\begin{aligned} L(x_1, \dots, x_n; \mu, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \\ &= \frac{1}{(2\pi)^{\frac{n}{2}} (\sigma^2)^{\frac{n}{2}}} e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}} \end{aligned}$$

两边取对数  $\ln L(x_1, \dots, x_n; \mu, \sigma^2) = -\sum_{i=1}^n \frac{1}{2\sigma^2} (x_i - \mu)^2 - \frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2)$

则似然方程组  $\begin{cases} \frac{\partial}{\partial \mu} \ln L = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L = 0 \end{cases} \Rightarrow \begin{cases} \hat{\mu} = \bar{x} \\ \hat{\sigma}^2 = s_n^2 \end{cases} \Rightarrow \mu \text{ 与 } \sigma^2 \text{ 的}$

极大似然估计量为  $\hat{\mu} = \bar{x}$ ,  $\hat{\sigma}^2 = s_n^2$



② 若  $\mu = \mu_0$  已知,  $\sigma^2$  未知, 现在求  $\sigma^2$  的极大似然估计量

解.  $L(x_1, \dots, x_n; \sigma^2) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2}$

两边取对数

$$\ln L(x_1, \dots, x_n; \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2 - \frac{n}{2} \ln(2\pi\sigma^2)$$

两边对  $\sigma^2$  求导得似然方程为

$$\frac{\partial \ln L(x_1, \dots, x_n; \sigma^2)}{\partial \sigma^2} = -\frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu_0)^2 - \frac{n}{2} \cdot \frac{1}{\sigma^2} = 0$$

$$\Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2 \text{ 为极大似然估计值.}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2 \text{ 为极大似然估计量.}$$

例2. 若母体  $X \sim N(\mu, \sigma^2)$  当  $\mu$  与  $\sigma^2$  都是未知参数时, 求  $\sigma^2$  的极大似然估计量

② 当  $\mu$  已知,  $\sigma^2$  未知时, 求  $\sigma^2$  的极大似然估计量的方差

解: ①  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \sim \frac{1}{n} \chi^2_{n-1}$

$$\therefore \frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-1} \therefore D\left(\frac{n\hat{\sigma}^2}{\sigma^2}\right) = 2(n-1) \therefore D(\hat{\sigma}^2) = \frac{2(n-1)}{n^2} \sigma^4$$

$$\textcircled{2} \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2 \therefore \frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2_n \therefore D(\hat{\sigma}^2) = \frac{2}{n} \sigma^4$$

5. 评价估计量好坏的两个标准 (有效性, 无偏性)

① 设  $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$  为参数  $\theta$  的一个估计量.

若  $E(\hat{\theta}) = \theta$ , 则  $\hat{\theta}$  为  $\theta$  的无偏估计量.

例:  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$  为母体方差的无偏估计量.

$$\therefore E(S^2) = \sigma^2$$

② 令  $I(\theta) = E \left( \frac{d \ln f(x; \theta)}{d\theta} \right)^2$ ,  $f(x; \theta)$  是把概率函数中的  $x$  换成  $x$ .

若  $\theta$  的一个无偏估计量  $\hat{\theta}$ , 满足  $D(\hat{\theta}) = \frac{1}{nI(\theta)}$ , 则

称  $\hat{\theta}$  为  $\theta$  的有效估计.

考题: 设母体  $X \sim N(\mu, \sigma^2)$ ,  $\mu$  为已知, 求证

$\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$  为  $\sigma^2$  的有效估计.